

梁吉

✉ 15262272286@163.com · ☎ (+86) 152-6227-2286 · 🌐 liangji-seu.github.io

求职意向：大模型推理优化, AI Infra, 嵌入式驱动

🎓 教育背景

东南大学	电子信息	硕士	2025.09 – 至今
考研成绩：初试排名 5, 复试排名 2			
东南大学	机器人工程	本科	2018.09 – 2022.06
本科绩点：3.75/4.0, 专业排名：8/40			

🔧 项目经历

基于 CUDA 的大模型推理框架开发与性能分析 2026.05 – 2026.06

设计并构建高效、灵活且可扩展的深度学习模型推理框架，通过优化模型加载与推理流程，提升处理速度和资源利用效率，支撑多种业务场景下的模型推理需求。

- 架构搭建**：实现支持 Llama 2/3.2、Qwen 等主流深度学习模型的推理框架，支持 YOLOv5、ResNet 等模型，支持 CPU/GPU 双后端推理与 KV-Cache 等常见优化手段。
- 算子调优**：针对 CUDA 算子进行深度定制和优化，实现 RMSNorm、MatMul、KV-Cache、MultiHead Attention、FlashAttention 等核心算子。
- 性能分析**：使用 Night-Compute、Night-System 等工具分析和调优算子性能；在 RTX 4090 上对 Qwen3-0.6B FP32 模型测试，单轮生成 332 个 decode tokens，TTFT 约 47.8ms，平均 decode latency 约 3.73ms/token，decode 吞吐约 267.9 token/s。
- 项目成果**：完成 Llama 2/3.2 与 Qwen 模型中多个复杂 CUDA 算子的开发和性能优化，覆盖 RMSNorm、MatMul、KV-Cache、MHA 等模块，提升推理速度与资源利用率。
- 框架研究**：深入学习 llama.cpp、vLLM 等大模型推理框架，对 llama.cpp 的内部实现和优化技巧进行研究，包括 PagedAttention、Continuous batching 等机制。

💼 工作经历

擎朗智能 嵌入式软件工程师 (BSP) 2022.06 – 2024.06

项目一：日本餐饮机型 T10 研发

- 负责软银定制机型的系统预研、原型机搭建到量产落地，支撑该机型通过灰度测试并在日本市场规模量产。
- 基于 RK3288 Android 6 平台，根据原理图和屏幕规格树完成显示链路适配，修改 DTS 与配置文件，实现 LVDS 与 eDP 双屏异显。
- 面向多 USB Camera 场景，通过 UDEV 规则和驱动层改造实现设备节点静态绑定，并将相机物理 ID 打通至 Framework/CameraService，提升应用层调用稳定性。
- 基于 Linux input 与 pinctrl 子系统完成多功能 GPIO 按键事件上报、上下拉配置和 Android Framework 层事件分发。
- 梳理 UI 板防火墙规则链，修改 drop 规则实现下层 RK3399 通过 RK3288 反向远程访问 PC。

项目二：酒店机器人 W3 电子架构优化 (降本增效)

- 独立负责核心主控系统架构更新与降本方案实施，推进显示、USB、双系统方案的预研和落地。
- 基于 RK3399 Android 10 平台编写 GM8775C 驱动并调试后端显示链路，实现 MIPI 转 LVDS 10.1 寸屏幕适配，并推动板卡厂商修复底层引脚布线问题。
- 针对量产线束仅支持 USB 2.0 的问题，重构 DeviceTree 中 USB 硬件拓扑，实现 Type-C to Type-A 的 USB 2.0 OTG，并支持应用层手动切换 host/device 模式。
- 预研双系统二合一架构，在磁盘中划分 OEM 镜像区域，通过 init.rc 自动挂载并扩容镜像，在分区内使用 QEMU 搭建轻量 Linux 系统。

✿ 技能证书/荣誉

大学英语四/六级 (CET-4/6)，东南大学二等学业奖学金，东南大学高等数学竞赛校级二等奖，第 17 届 RoboCup 机器人竞赛校级优秀奖。

i 自我评价

- **专业素养**：基础知识掌握扎实，具备较强的抗压能力、实验设计与数据分析能力，重视理论与实践相结合，熟悉计算机体系架构。
- **实践能力**：有良好的任务沟通能力和解决问题习惯，以及动手解决问题的能力。
- **团队合作**：具备良好的团队协作精神，善于与他人沟通合作，及时汇报工作进度，抗压能力强。